

基于声学系统的物理局部学习神经网络构建与实验研究

张瑞琦，复旦大学物理学系

摘要：随着深度学习模型规模的不断扩张，基于传统冯·诺依曼架构的数字计算硬件日益凸显出算力受限与高昂能耗的双重瓶颈。物理神经网络(Physical Neural Networks, PNN)通过直接利用介质的物理演化特性进行计算，展现出低功耗与高并行的巨大潜力。然而，传统神经网络广泛采用的反向传播(Back Propagation, BP)算法依赖精确可微的数学模型，难以直接应用于存在噪声、非理想性和未知扰动的真实物理系统。因此，研究者提出了物理局部学习(Physical Local Learning, PhyLL)等无需全局误差反向传播的训练方法，为实体物理神经网络的训练提供了新的途径。

基于此，本研究以声学腔体为物理计算载体，引入 PhyLL 算法，设计并搭建了一种声学物理神经网络实验系统，并对其网络性能进行了实验验证。在 7 分类元音识别任务中，本研究引入实验前扫频机制、高精度幅值提取算法以及动态阈值归一化策略，有效抑制了系统噪声与共振极值对信号质量的影响。实验结果表明，优化后的声学计算平台最高可达到 98% (测试集与训练集) 的分类准确率，验证了该声学系统进行高维特征映射的可行性，并为后续声学物理神经网络的优化与扩展提供了实验基础。

关键词：物理神经网络；声学计算；物理局部学习；特征映射；高精度信号提取

1. 引言

1.1 研究背景与意义

随着深度学习模型参数规模的持续增长，基于冯·诺依曼架构的传统硅基计算系统在数据存储与传输过程中面临显著的能耗瓶颈。此背景下，物理神经网络(Physical Neural Networks, PNNs)作为一种利用物理系统直接执行计算的新型范式逐渐受到关注[1]。该类方法利用物理介质的输入输出响应过程来执行神经网络计算，实现“物理过程即计算”的信息处理范式，从而降低显式数值计算与数据搬运过程中的能耗。

在多种物理实现路径中，易于构建与观测的声学物理神经网络具有较高的实验可行性。在声学腔体中，声波传播会产生反射、干涉等波动效应，这些过程一定程度上对应于高维信号在空间中的混合与变换，因此可用于实现高维特征的物理映射与信息处理[2]。基于此，构建声学物理神经网络实验系统，有助于在真实物理环境中验证 PNN 的计算可行性，并为进一步研究物理介质中的信息表示与学

习过程提供实验基础。

1.2 物理局部学习算法

尽管物理神经网络具有潜在的计算优势,但其训练过程在实际实现中仍面临一定挑战。传统深度学习通常依赖反向传播算法(Back Propagation, BP)进行参数优化,而该方法要求网络具备明确且可微的全局数学模型。然而,在真实物理系统中,环境噪声、物理过程的“黑箱”效应等因素使得构建精确可微模型变得困难,限制了BP算法在物理神经网络中的应用。因此,受Hinton提出的Forward-Forward算法启发[3],研究者提出了一种无需通过反向传播优化参数的学习机制:物理局部学习算法(Physical Local Learning,下文简称PhyLL)[4]。具体实现上,其通过一组正负样本的双前向传播,在每一层网络进行参数的独立更新,训练准则为:以各层的输出向量与参考的目标向量间的余弦相似度(Goodness)为优化指标,让正样本更接近参考向量的方向,负样本趋于远离。此算法最大的优势在于:其不需要对物理层进行精确的可微数学建模,因此非常适合在真实的物理系统上运行,具备良好的物理适应性和鲁棒性。

1.3 本研究主要工作

从底层硬件搭建到上层算法调优,本研究致力于完整构建一个基于声学腔体的物理局部学习神经网络系统,并对其内部机制进行深入探究。核心工作如下:

- 1) 设计并搭建了基于扬声器、麦克风阵列与亚克力密闭腔体的物理计算环境,跑通了“数据编码——音频生成——物理腔体调整与实验——信号采集与分析——网络训练”的完整实验流程。
- 2) 针对声学腔体共振极值导致的信号压制与失真,引入了前置扫频机制、抛物线亚像素高精度幅值提取算法及动态阈值归一化策略。在元音7分类任务中,实现了高达98%(测试集和训练集)的分类准确率,验证了系统的计算潜力。
- 3) 通过在输入层引入“弥散化”矩阵,测试了系统在消除显式标签特征后的深度解耦能力,为探索物理系统更深层次的非线性计算机制奠定了实验基础。

2. 声学物理神经网络系统架构

2.1 实验装置

声学腔体在网络中的本质作用,是将20维“符号化”的离散数字转化为具有物理演化特性的连续声场,使其映射到一个无限维的声学状态空间中。为确保声学物理映射的稳定性与封闭性,本研究定制了壁厚为10 mm的密闭亚克力声学空腔作为核心计算载体。腔体内部可通过灵活配置亚克力圆柱体或不同阻抗的几何散射介质,动态调整声场的映射结构。

在输入输出配置上，装置输入端采用多通道独立音频接口（UMC404HD 声卡）驱动 4 路扬声器（音孔直径约 102 mm）；输出端则对应布置 4 路麦克风。每次实验可从预设的 5 个扬声器位点与 15 个麦克风位点中，分别自主选择 4 个作为激励源与接收端，极大地扩展了系统的配置空间与可探索深度。布置麦克风进行信号接收的过程，本质上即是对内部无限维的连续声学状态空间进行特定切面的降维观察。




图 1 声学物理神经网络原型实验装置

2.2 数据编码与流向

物理实体仅是计算的载体，要将其真正纳入神经网络的训练流，需建立一套完整的“数字——物理——数字”信息流转逻辑。整个系统的数据映射与流向遵循以下机制：

1) 数字“标签+特征”编码：

在数字信号端，系统将元音数据集的 7 维 One-hot 标签信息与 12 维特征信息进行拼接，并补齐 1 维预留占位符，统一编码为完整的 20 维输入向量。通过全局最大值归一化，将数值严格约束在 $[0, 1]$ 范围内，以适配硬件播放的物理限制。

2) 多声道音频生成与播放：

将编码后的 20 维输入向量均分为 4 组（每组 5 维），各组数值分别映射为 5 个基准频率上的幅值。在 48 kHz 采样率下，系统通过多频正弦波叠加合成激励音频，并分配至 4 路扬声器通道。为消除音频起止阶段的瞬态阶跃噪声，对激励信号两端施加了基于正弦包络的平滑加窗处理（Fade-in/Fade-out）。随后，声波脉冲在密闭亚克力腔体内经历反射、干涉相长与相消等物理演化，完成了从离散数据到连续声场的转变。

3) 信号采集与特征提取：

输出端麦克风阵列实时捕捉经过腔体物理调制后的混合声波。系统对采集到的录音进行时域截断，并通过快速傅里叶变换（FFT）提取 4 个物理接收通道在 5 个目标基准频率上的声学幅值。这些幅值被重新拼接重组为 20 维的物理层输出向量，完成了从无限维连续物理声场到低维离散数字特征的降维投影。

4) 网络训练与权重更新

通过批量实验，获取物理层的输出后，系统将正负样本对应的输出数据统一反馈给数字端的 Readout 层。利用 PhyLL 算法，计算物理层输出与固定参考向量的余弦相似度（Goodness 评分），据此构建正负样本的对比损失函数，并利用优化器在数字端直接完成权重矩阵的独立更新，从而彻底打通了完整的前向训练流水线。

3. 数据提取算法迭代与系统调优机制

与高确定性的纯数字计算不同，真实的物理计算系统具有极强的环境敏感性与不可预见性。在早期基准测试中，由于环境噪声、腔体固有共振以及离散采样等因素引起的失真，往往会导致系统的特征映射表现出极大的脆弱性。为了将物理底座从一个“不可控的黑盒”改造为高鲁棒性的计算平台，本研究在针对数据处理的实验环境进行了以下迭代调优。

3.1 音频分析程序的算法改良

在从连续模拟声场到离散数字特征的转换过程中，音频信号提取程序的严谨性直接决定了反馈给 PhyLL 网络的有效信息质量。

实体声学计算平台在发声起止瞬间常伴随扬声器的起振瞬态与信道产生的瞬态噪声。若直接进行全量截取，非稳态的物理噪声会影响真实数据。为此，本研究首先在时域层引入了稳态能量截取算法。音频分析程序通过计算采集信号的平滑能量包络并设定动态触发阈值，精确定位上升沿。程序设定暂态跳过时间为 150 ms，以避免物理腔体与扬声器的初始振荡期，随后仅截取中间极其稳定的 200 ms 时间窗作为有效稳态信号。

此外，针对快速傅里叶变换（FFT）中的“栅栏效应”可能导致的幅值提取偏差，程序应用了平顶窗（Flat top window）以最大程度保证幅值计算的绝对精度。在此基础上，引入抛物线亚像素插值（Parabolic Sub-bin Interpolation）算法，利用离散谱线峰值及其两侧的幅值进行二阶多项式拟合，从而准确计算出偏离离散频点刻度的真实物理共振峰幅值与频率，获得了高保真的线性幅值。




图 2 音频时域分析中的稳态能量截取算法示意图。

上图为完整物理采集音频的能量包络及动态触发阈值；下图为局部特征放大视图。图中黄色高亮区块为跳过 150 ms 初始起振暂态后，提取的 200 ms 稳态有效信号窗。

3.2 前置扫频机制的引入

在早期的基础分类任务中，信号编码通常采用预设的固定频率组合（如 300、450、600、750、900Hz）。然而，初步实验发现，密闭亚克力腔体在特定频段下会产生强烈的空间驻波效应，导致某些固定频率恰好落在声学节点（幅值极小）或波腹（幅值极大）上。为此，本研究在每次正式实验前引入了扫频机制。在正式数据调制前，系统会先对腔体的声学响应进行宽频扫描（200-1200Hz），避开极端共振区与“低谷区”，挑选出 5 个响应最平滑、最稳定的频段作为实际工作基频，从而从物理信道层面提升了数据传输的可靠性。




图 3 密闭声学腔体的前置宽频扫描与基频筛选响应图。

图中曲线展示了 4 路麦克风接收通道在 200~1200 Hz 扫频激励下的响应。图中紫色虚线标示了算法自主避开极端共振峰与驻波节点后，自动筛选出的 5 个工作基准频率。

3.3 物理极值抑制与归一化策略优化

即使确立了前置扫频机制，实验数据表明，在声场演化中，腔体中深度的多频干涉及外部噪声依然会产生极端响应峰值或电信号毛刺。在采用传统的全局最大值归一化时，这些极值会导致 99% 以上的物理层数据被压缩在极小的数值区间内，严重压缩了有效特征的分布空间，导致可分性退化。

为解决此问题，本研究对数据的归一化策略进行了渐进式调优，摒弃了全局最大值映射，转而采用分位数截断机制。在初期调优中，引入了 99.5% 分位数截断，一定程度上缓解了极值压制；随着对数据集中程度的深入分析，进一步将截断分位数下调并锚定在 94%。系统将高于 94% 分位数的极值强制截断为 1，而将剩余数据按比例映射至 $[0,1]$ 之间，成功释放了绝大多数真实微小的有效信号的数值分布空间，恢复了物理特征的可分性，是后续准确率实现突破的关键步骤。




图 4 不同归一化策略下的物理层特征数据分布对比。

(a) 全局最大值归一化：绝大多数有效信号的幅值被压缩至低值区间，导致数据丧失区分度； (b) 94%分位数截断机制：强制截断极值后，数据的数值分布空间被成功释放。

3.4 实验环境隔离

为排除外部环境噪声的干扰，进一步加强实验的大规模、稳定开展，本研究引入了严格的物理隔离机制，将整套实体声学计算装置（包含声学空腔、扬声器与麦克风阵列）整体迁移至定制的消音柜内运行。消音柜的引入有效阻断了外部随机噪声，极大提升了物理层特征的信噪比与系统的重复稳定性。




图 5 优化后的声学物理神经网络平台

4. 7 分类元音识别任务的实验结果

本研究基于 Vowel Dataset 开展 7 分类元音识别任务。数据集的每个原始样本由 12 维声学特征构成，经标准化预处理后，按 8:2 随机划分为训练集（206 个样本）与测试集（52 个样本）。网络基于 PhyLL 算法进行训练，核心超参数配置为：内循环更新轮次（N_INNER）为 10，学习率（Learning Rate）设为 0.0005，总训练周期（Epochs）为 200 轮。

4.1 基础分类任务

本研究对系统进行了多轮次物理实测试验。依托基础的物理映射，网络最高可取得约 94% 的分类准确率；但受制于声学腔体极强的环境敏感性，该结果的复现存在较大波动。

在全面部署了第 3 章所述的调优机制，并将物理装置整体迁入消音柜以隔绝外部环境噪声后，系统的分类性能获得显著提升：

一方面，在消音柜隔离环境下开展的新一轮实测中，训练集与测试集准确率分别

达到了 96.12%和 96.15%；另一方面，把迭代后的数据处理算法重新应用于此前获取的历史实验数据后，其训练集与测试集的准确率分别由原先的 94.17%和 94.23%上升至 98.06%和 98.08%。

上述结果证实了当前的声学物理神经网络在执行高维特征映射与分类任务上的有效性与计算潜力。但需客观指出的是，受限于现阶段的物理实验周期，该准确率主要代表了系统在理想物理状态下的算力上限，未来工作将进一步增加实验轮次，以评估、确立其稳定性与鲁棒性。




图 6 优化后的训练收敛曲线、训练集（左）和测试集（右）的混淆矩阵。

上图为消音柜隔离环境下的实验结果；下图为应用优化算法重构历史数据的实验结果。




图 7 PhyLL 算法正负样本 Goodness 评分分布对比。

左图为消音柜隔离环境下的结果；右图为应用优化算法重构历史数据的结果。图中清晰展示了网络训练后正样本（蓝）与负样本（红）在相似度评分上的显著分离。

4.2 输入层标签“隐式化”实验

本研究进一步开展了输入数据的“弥散化”实验，通过在输入端引入一个 20×20 的线性变换矩阵，将原本的 One-hot 标签特征（例如呈现明显的 $[1, 0, 0, 0, \dots]$ 结构）进行隐式化，使其与特征混合，以此检验系统对高度混合输入的分类能力。

实验结果表明，在弥散化数据输入下，网络在训练集上依然维持了约 93% 的高准确率，但测试集准确率却骤降至 50% 左右。这一典型的过拟合现象，暴露出系统在应对高度混合输入时遇到了极大的物理映射阻力。




图 8 “弥散化”实验的训练收敛曲线、训练集（左）和测试集（右）的混淆矩阵。

左侧训练收敛曲线显示训练集准确率逼近 93%，而测试集准确率停滞在 50%。

与训练集对角线的高度集中不同，测试集矩阵呈现出明显的错分现象。




图 9 “弥散化”实验的 Goodness 评分分布与正负样本评分差距分布。

左图为正、负样本的 Goodness 分布，右图为对应样本的 Goodness 差值分布。图中正负样本的评分区间出现了部分重叠，未能有效分离。

4.3 物理映射分析

针对上述弥散化实验的数据，本研究推测其根本原因可能源于声学系统固有的映射偏置，以及当前腔体非线性映射程度的不足。

尽管消音隔离环境排除了外部底噪，但空腔内部复杂的声学模态（如固有的驻波模式、材料吸收的不均匀性）客观上构建了一个具有强烈局部偏好性的映射空间。在输入特征未被弥散化时，特定频段的独立能量足以支撑浅层分类；然而，当输入信息被线性矩阵弥散至全局维度后，高度耦合的信号需要物理载体提供极强的非线性映射才能实现有效解耦。在此条件下，网络在训练过程中极易陷入“捷径学习”，倾向于死记硬背训练样本触发的偶然局部共振特征，而非提取具备泛化能力的元音本征特征。

这种由物理载体固有偏置与非线性表达能力受限共同导致的归类“倾斜”，揭示了当前声学腔体的局限性，“进一步提升系统的非线性映射能力”成为当前声学

计算架构亟需攻克的核心挑战。

5. 结论与未来展望

5.1 总结

本研究针对传统数字计算硬件在 AI 时代面临的能耗与算力瓶颈，探索了物理神经网络（PNN）这一新兴计算范式，完整构建了一种基于声学腔体与物理局部学习（PhyLL）算法的声学物理神经网络实验系统。针对真实声学实验过程中的非理想效应，本研究系统实施了实验前置扫频机制、稳态能量截取、平顶窗结合亚像素插值的幅值提取算法，以及 94% 分位数的归一化策略等调优工作。

实验结果表明，在 7 分类元音识别任务中：在消音柜环境下，系统取得了训练集与测试集双 96% 的高准确率；在历史最佳环境配置下，分类准确率则达到了 98%，验证了声学物理神经网络执行高维数据计算的可行性。

5.2 未来展望

基于当前声学物理神经网络的表现与硬件局限性，未来的研究工作将主要围绕以下两个方向展开：

- 1) 夯实现有机制与基础问题排查：**继续优化现有的声学前向演化架构，深入探究物理腔体内部空间布局、麦克风阵列排布对映射的影响；进一步增加实验轮次，以全面评估并确立系统的稳定性与鲁棒性
- 2) 在声学腔体内部建立真正的“幅值非线性”响应机制：**非线性计算是神经网络具备复杂拟合与泛化能力的基石。现有系统在数据的非线性映射层面仍具局限性，未来将致力于在声学腔体内构建真正的幅值非线性演化机制。具体的探索方向为：在声学腔体内引入对空气振动敏感的柔性介质（如弹性薄膜），或利用特定几何机构激发强声学效应（如使用薄壁空心管诱导局部空气共振），形成“输入幅值线性变化时，输出幅值非线性变化”的映射网络。系统将能够在声学腔体内部直接实现等效于“激活函数”的非线性计算，推动物理神经网络由高维状态映射走向深层物理非线性演化。

参考文献:

- [1] Wright, L.G., Onodera, T., Stein, M.M. et al. Deep physical neural networks trained with backpropagation. *Nature* 601, 549 – 555 (2022).
- [2] Tyler W. Hughes et al., Wave physics as an analog recurrent neural network. *Sci. Adv.* 5, eaay6946 (2019).
- [3] Hinton, G. "The Forward-Forward Algorithm: Some Preliminary Investigations." *arXiv preprint arXiv:2212.13345* (2022).
- [4] Ali Momeni et al. , Backpropagation-free training of deep physical neural networks. *Science* 382, 1297-1303 (2023).